INSTITUTO POLITÉCNICO DO CÁVADO E DO AVE

Escola Superior de Tecnologia

RELATÓRIO DO TRABALHO PRÁTICO I

Integração de dados de meteorologia e qualidade do ar

Processo ETL com Pentaho Data Integration e PostgreSQL

Unidade Curricular: Integração de Sistemas de Informação
Licenciatura em Engenharia de Sistemas Informáticos
Ano letivo 2026/2027

Autor: Afonso Ferreira | Número: 27981

Barcelos, outubro de 2026

Índice

Índice 2
Resumo 2
1. Enquadramento 2
2. Problema e objetivos 3
3. Estratégia utilizada 3
3.1 Arquitetura do processo 3
3.2 Fontes e formatos 3
4. Transformações 4
4.1 T3_limpeza_locais 4
4.2 T1_extract_meteo 4
4.3 T2_extract_qualidade_ar 4
4.4 T4_transformacao 4
5. Job e orquestração 5
6. Persistência e resultados 5
6.1 Modelo de dados 5
6.2 Verificações realizadas 5
7. Demonstração em vídeo 5
8. Conclusão e trabalhos futuros 6
Referências bibliográficas 6

Resumo

Este trabalho desenvolve um processo de integração de dados ambientais com Pentaho Data Integration (PDI) e PostgreSQL. A solução utiliza um ficheiro CSV com locais e coordenadas e duas APIs REST da Open-Meteo, que devolvem dados em JSON: meteorologia horária e qualidade do ar. As transformações limpam e deduplicam os locais, validam os registos, extraem as variáveis das respostas das APIs, convertem os tipos e carregam os dados em tabelas de staging. No T4, as tabelas são cruzadas por local e instante temporal, sendo criadas medições detalhadas e uma saída agrupada por local e dia. A execução confirmada registou 252 linhas em `medicoes` e 21 em `resumo_diario`. O mapeamento do resultado agregado foi completado no T4 e os valores das métricas em `resumo_diario` foram confirmados no PostgreSQL.

Palavras-chave: ETL; Pentaho Data Integration; PostgreSQL; meteorologia; qualidade do ar; integração de dados.

1. Enquadramento

O trabalho foi realizado no âmbito da unidade curricular de Integração de Sistemas de Informação, da Licenciatura em Engenharia de Sistemas Informáticos da Escola Superior de Tecnologia do Instituto Politécnico do Cávado e do Ave, no ano letivo 2026/2027. O projeto aplica o ciclo ETL (Extract, Transform,

Load) à integração de fontes ambientais heterogéneas, de acordo com o objetivo definido no enunciado da unidade curricular.

O desenvolvimento utiliza o Spoon, interface gráfica do Pentaho Data Integration, para definir transformações e um Job de orquestração. O PostgreSQL funciona como destino persistente e como área de staging para separar a extração das operações de integração.

2. Problema e objetivos

Os dados meteorológicos e os dados de qualidade do ar são publicados por serviços distintos, com estruturas próprias e valores associados a coordenadas e instantes horários. Sem integração, torna-se difícil consultar conjuntamente temperatura, humidade e concentrações de poluentes para um mesmo local e período.

O problema tratado consiste em recolher as duas séries horárias para os locais definidos, preparar os dados de entrada, relacionar os registos temporais e disponibilizar medições e agregados diários numa base de dados relacional.

Os objetivos concretos são:

- Importar os locais a partir de um CSV e remover duplicados antes das consultas às APIs.
- Validar os dados dos locais e encaminhar registos aceites e rejeitados para ficheiros distintos.
- Consumir duas APIs REST e interpretar as respostas JSON para obter variáveis horárias.
- Converter datas e valores numéricos e carregar cada fonte em tabelas de staging PostgreSQL.
- Juntar meteorologia e qualidade do ar por local e data/hora, persistir as medições e construir uma agregação diária.
- Executar as transformações numa sequência controlada através de um Job Pentaho.

3. Estratégia utilizada

3.1 Arquitetura do processo

A solução divide o processo em quatro transformações. O T3 prepara a lista de locais. O T1 e o T2 consultam as APIs em separado e carregam tabelas de staging. O T4 combina as tabelas e escreve os resultados finais. O Job principal executa as transformações pela ordem T3, T1, T2 e T4, terminando no passo de sucesso.

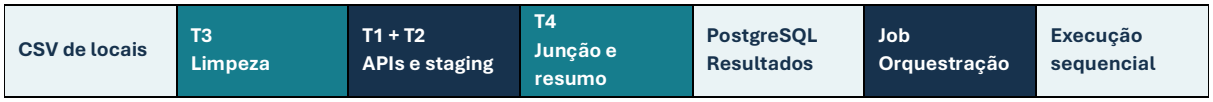


Figura 1 — Visão geral do processo ETL implementado.

3.2 Fontes e formatos

Fonte	Formato	Dados utilizados
`data/locais.csv`	CSV	Identificador/nome do local, concelho e coordenadas; inclui também campo de contacto.
Open-Meteo Weather Forecast API	REST / JSON	Série horária de temperatura a 2 m e humidade relativa a 2 m.
Open-Meteo Air Quality API	REST / JSON	Série horária de PM10, PM2.5, dióxido de azoto (NO_2) e ozono (O_3).
PostgreSQL	Tabelas relacionais	Staging das fontes, medições integradas e resumo diário.

O fluxo usa efetivamente CSV e JSON, além de persistência relacional no PostgreSQL. Existe um ficheiro `data/limites.xml` na pasta do projeto, mas a transformação atual não o lê; por isso, XML não é contabilizado como formato efetivamente processado.

4. Transformações

4.1 T3_limpeza_locais

O T3 lê `data/locais.csv`, aplica operações a texto e ordena os registos para que a remoção de duplicados seja consistente. O passo `Unique rows` elimina repetições. A validação por expressão regular avalia o campo de email e o passo `Filter rows` separa os registos aceites dos rejeitados. Existe ainda um ramo de saída para os locais deduplicados, usado como entrada pelos T1 e T2.

A transformação escreve três ficheiros na pasta `export`: `locais_deduplicados.csv`, `locais_aceites.csv` e `locais_rejeitados.csv`. Os nomes finais efetivamente gerados devem ser confirmados, pois a configuração do Spoon pode acrescentar a extensão definida no passo de saída. A validação de email não equivale a anonimização; os emails não são mascarados pelo fluxo atual.

4.2 T1_extract_meteo

O T1 lê a lista deduplicada e constrói, através do passo `Formula`, o URL da API meteorológica com as coordenadas de cada local. O passo `REST client` obtém a resposta e `JSON input` extrai os arrays horários `time`, `temperature_2m` e `relative_humidity_2m`. Em `Select values`, `data_hora` é convertido para data/hora e temperatura e humidade para valores numéricos. O resultado é carregado em `stg_meteo`, associando o concelho ao campo `local`.

4.3 T2_extract_qualidade_ar

O T2 segue a mesma estratégia de leitura dos locais e construção do pedido REST, mas consulta a API de qualidade do ar. O parser JSON extrai `time`, `pm10`, `pm2_5`, `nitrogen_dioxide` e `ozone`. A transformação converte a data/hora e os poluentes para tipos adequados e carrega os registos em `stg_qualidade_ar`. A execução do T2 depende de conectividade à Internet e da disponibilidade dos serviços Open-Meteo.

4.4 T4_transformacao

O passo `Table input` executa uma consulta sobre as tabelas de staging. A consulta usa `stg_meteo` como conjunto principal e faz um `LEFT JOIN` a `stg_qualidade_ar`, comparando o local depois de remover espaços laterais e exigindo igualdade de `data_hora`. A escolha de `LEFT JOIN` preserva registos meteorológicos mesmo quando não existe correspondência de qualidade do ar.

A primeira saída de dados grava em `medicoes` as colunas local, data/hora, temperatura, humidade e os quatro poluentes. A outra saída usa `Group by`, agrupando por `local` e `data`, para calcular temperatura média, mínima e máxima, médias de PM2.5 e PM10 e máximo de PM2.5. Essa saída destina-se à tabela `resumo_diario`.

O mapeamento de `Table output 2` foi atualizado para enviar `local`, `data` e as métricas produzidas pelo `Group by` para as colunas correspondentes de `resumo_diario`. A consulta de verificação no PostgreSQL confirmou valores em `temp_media`, `temp_min`, `temp_max`, `pm2_5_media`, `pm2_5_max` e `pm10_media`.

5. Job e orquestração

O ficheiro `transformacoes/J_pipeline_principal.kjb` contém um início, quatro entradas de transformação e uma entrada final de sucesso. Os saltos estão configurados para avançar quando a entrada anterior termina com sucesso.

Ordem	Entrada do Job	Responsabilidade
1	T3_limpeza_locais.ktr	Preparar e exportar os ficheiros dos locais.
2	T1_extract_meteo.ktr	Consultar meteorologia e carregar `stg_meteo`.
3	T2_extract_qualidade_ar.ktr	Consultar qualidade do ar e carregar `stg_qualidade_ar`.
4	T4_transformacao.ktr	Juntar fontes e carregar as tabelas finais.
5	Success	Assinalar conclusão normal do Job.

O Job não está configurado para escrever na tabela `log_execucoes`; o acompanhamento da execução é feito pelo registo apresentado no Spoon. Os ficheiros KTR/KJB guardam caminhos absolutos da pasta OneDrive do computador de desenvolvimento, pelo que precisam de ser atualizados se o projeto for movido.

6. Persistência e resultados

6.1 Modelo de dados

Tabela	Papel no processo
`stg_meteo`	Área temporária com local, data_hora, temperatura e humidade.
`stg_qualidade_ar`	Área temporária com local, data_hora e PM10, PM2.5, NO_2 e O_3.
`medicoes`	Tabela final horária com variáveis meteorológicas e poluentes; chave única em (local, data_hora).
`resumo_diario`	Tabela de destino da agregação por local e data; chave única em (local, data).
`log_execucoes`	Tabela existente na base; a utilização pelo Job atual não foi confirmada.

6.2 Verificações realizadas

Na última execução confirmada no pgAdmin, a consulta de contagem devolveu 252 registos em `medicoes` e 21 registos em `resumo_diario`. Além da contagem, foi consultada uma amostra das linhas de `resumo_diario` e confirmada a presença de valores nas métricas agregadas. Assim, a validação abrange tanto a criação das linhas como o preenchimento das colunas calculadas.

A chave única por local e data/hora impede duplicados na tabela de medições. Uma reexecução de T4 sem limpeza ou atualização prévia pode causar violação de chave única, dado que a transformação está configurada para inserir. Deve ser definida uma estratégia de recarga, por exemplo limpar os destinos antes da execução ou usar uma operação de upsert, conforme o objetivo do trabalho.

7. Demonstração em vídeo

O enunciado pede um vídeo de demonstração acessível através de QR Code. Como o vídeo ainda não está publicado, fica reservado abaixo o espaço para adicionar o QR Code e o respetivo endereço antes da entrega final.



Endereço do vídeo: https://youtu.be/5Dmj7uK0YDw

Sugestão de conteúdo para a gravação: mostrar o Job no Spoon, acompanhar a execução T3 → T1 → T2 → T4, consultar as contagens no pgAdmin e verificar que as colunas agregadas de `resumo_diario` ficam preenchidas e confirmar que as métricas agregadas estão preenchidas.

8. Conclusão e trabalhos futuros

O projeto implementa um fluxo ETL funcional que integra um ficheiro CSV, duas APIs REST com respostas JSON, transformações Pentaho e uma base de dados PostgreSQL. A limpeza dos locais, a extração horária, a preparação das tabelas de staging, o cruzamento por local/data-hora e a orquestração sequencial estão representados nas transformações entregues. A execução confirmada gravou 252 linhas de medições e criou 21 linhas para o resumo diário.

O mapeamento entre o `Group by` e as colunas de `resumo_diario` foi corrigido e os valores agregados foram confirmados no pgAdmin. Como melhorias futuras, recomenda-se tornar os caminhos relativos, definir uma estratégia segura para reexecuções, integrar o XML de limites e, se adequado, acrescentar visualização, alertas ou envio remoto de ficheiros.

Referências bibliográficas

[1] Ferreira, L.; Ribeiro, Ó. (2026). Integração de Sistemas de Informação, Licenciatura em Engenharia de Sistemas Informáticos, 2026/27: Trabalho Prático I. Enunciado da unidade curricular.

[2] Open-Meteo. Weather Forecast API documentation. https://open-meteo.com/en/docs (consultado em 19/10/2026).

[3] Open-Meteo. Air Quality API documentation. https://open-meteo.com/en/docs/air-quality-api (consultado em 19/10/2026).

[4] Hitachi Vantara. Pentaho Data Integration documentation. https://docs.pentaho.com/pdia-data-integration (consultado em 19/10/2026).

[5] The PostgreSQL Global Development Group. PostgreSQL Documentation. https://www.postgresql.org/docs/ (consultado em 19/10/2026).